

Introdução à Estatística Multivariada

Disciplina: Modelagem Estatística

Instrutor: Luiz Max Carvalho

Monitores: Eduardo Adame & Ezequiel Braga

Março 2024

Introdução

A ideia desse documento é auxiliar na transição para a Estatística Multivariada. É importante estar bem afiado em Álgebra Linear e (obviamente) nos conteúdos vistos em Inferência Estatística. As referências principais serão o [Petersen e Pedersen \(2008\)](#) e o [Soch et al. \(2024\)](#).

Vetores Aleatórios

Ao invés de lidarmos com uma variável aleatória $X \in \mathcal{X} \subseteq \mathbb{R}$, com $\mu = \mathbb{E}[X]$ e $\sigma^2 = \mathbb{V}[X] = \mathbb{E}[(X - \mathbb{E}[X])^2]$, introduzimos agora vetores aleatórios. Por exemplo, $\mathbf{X} \in \mathcal{X}^n$, com **vetor de média** $\boldsymbol{\mu}$ tal que $\mu_i = \mathbb{E}[X_i]$ (denotamos $\boldsymbol{\mu} = \mathbb{E}[\mathbf{X}]$) e **matriz de covariância** $\boldsymbol{\Sigma} = \mathbb{E}[(\mathbf{X} - \mathbb{E}[\mathbf{X}])(\mathbf{X} - \mathbb{E}[\mathbf{X}])^\top]$, que vem de um produto externo. Lembre-se que perdemos comutatividade ao trabalhar em $\mathcal{X}^{n \times n}$.

Formas Quadráticas

Uma forma quadrática é uma expressão polinomial em que cada termo possui grau 2. Por exemplo, $y_1^2 + y_2^2$ e $2y_1^2 + y_2^2 + 3y_1y_2$ são formas quadráticas em y_1 e y_2 , mas $y_1^2 + y_2^2 + 2y_1$ e $y_1^2 + 3y_2^2 + 2$ não são.

Seja \mathbf{A} uma matriz simétrica. Então, a expressão $\mathbf{y}^\top \mathbf{A} \mathbf{y} = \sum_i \sum_j a_{ij} y_i y_j$ é uma forma quadrática nos y_i 's. Analogamente, a expressão $(\mathbf{y} - \boldsymbol{\mu})^\top \mathbf{V}^{-1} (\mathbf{y} - \boldsymbol{\mu})$ é uma forma quadrática nos termos $(y_i - \mu_i)$. Quando $\mathbf{y}^\top \mathbf{A} \mathbf{y} > 0$, $\forall \mathbf{y} \neq \mathbf{0}$, diz-se que a forma quadrática (e a matriz \mathbf{A}) é positiva definida. Além disso, o posto da matrix \mathbf{A} é chamado de número de graus de liberdade da forma quadrática.

Teorema (Cochran). *Seja X_1, X_2, \dots, X_n uma amostra aleatória da distribuição normal com média 0 e varância σ^2 . Sejam $Q = \sum_{i=1}^n X_i^2$ e Q_1, \dots, Q_k formas quadráticas tais que $Q = \sum_{i=1}^k Q_i$, onde Q_i possui m_i graus de liberdade. Então, Q_1, \dots, Q_k são variáveis aleatórias independentes com $\frac{Q_i}{\sigma^2} \sim \chi^2(m_i)$ ($i = 1, \dots, k$) se, e somente se, $\sum_{i=1}^k m_i = n$.*

Uma consequência do teorema acima é que se $X_1^2 \sim \chi^2(m)$ e $X_2^2 \sim \chi^2(k)$ são independentes, então, $X^2 = X_1^2 - X_2^2 \sim \chi^2(m - k)$, desde que $X^2 \geq 0$ e $m > k$.

Identidades Relevantes

Seja \mathbf{X} variável aleatória com média $\boldsymbol{\mu}$ e matriz de covariância $\boldsymbol{\Sigma}$

- $\mathbb{E}[\mathbf{A}\mathbf{X} + \mathbf{B}] = \mathbf{A}\boldsymbol{\mu} + \mathbf{B}$
- $\mathbb{V}[\mathbf{A}\mathbf{X}] = \mathbf{A}\boldsymbol{\Sigma}\mathbf{A}^\top$
- $\mathbb{E}[\mathbf{X}\mathbf{X}^\top] = \boldsymbol{\Sigma} + \boldsymbol{\mu}\boldsymbol{\mu}^\top$

Matrizes de Covariância

A noção de variância passa a ser representada, em geral, em termos de covariância. Sabemos desde a parte univariada que $\text{Cov}[X, X] = \mathbb{V}[X]$ e isso continua valendo aqui.

Sabemos também que essa matriz será, ao menos, semi-definida positiva, pois $\forall w \in \mathbb{R}^n$ temos que:

$$\begin{aligned}\mathbb{V}[w^\top \mathbf{X}] &= w^\top \mathbb{V}[\mathbf{X}]w = w^\top \mathbb{E} \left[(\mathbf{X} - \mathbb{E}[\mathbf{X}])(\mathbf{X} - \mathbb{E}[\mathbf{X}])^\top \right] w, \\ &= \mathbb{E} \left[w^\top (\mathbf{X} - \mathbb{E}[\mathbf{X}])(\mathbf{X} - \mathbb{E}[\mathbf{X}])^\top w \right], \\ &= \mathbb{E} \left[\left[w^\top (\mathbf{X} - \mathbb{E}[\mathbf{X}]) \right]^2 \right] \geq 0.\end{aligned}$$

Principais Distribuições Multivariadas

Multivariada Normal

Seja $\mathbf{X} \in \mathbb{R}^n$. Então, \mathbf{X} é normalmente distribuído com média $\boldsymbol{\mu} \in \mathbb{R}^n$ e matriz de covariância $\boldsymbol{\Sigma} \in \mathbb{R}^{n \times n}$ ($\mathbf{X} \sim \mathcal{N}(\boldsymbol{\mu}, \boldsymbol{\Sigma})$) se, e somente se, sua p.d.f é dada por

$$f(\mathbf{x}; \boldsymbol{\mu}, \boldsymbol{\Sigma}) = \frac{1}{\sqrt{(2\pi)^n |\boldsymbol{\Sigma}|}} \exp \left[-\frac{1}{2}(\mathbf{x} - \boldsymbol{\mu})^\top \boldsymbol{\Sigma}^{-1}(\mathbf{x} - \boldsymbol{\mu}) \right].$$

Dirichlet (Generalização da Beta)

Seja $\mathbf{X} \in \mathbb{R}^n$. Então, \mathbf{X} segue a distribuição Dirichlet com parâmetros de concentração $\boldsymbol{\alpha} = [\alpha_1, \alpha_2, \dots, \alpha_n]$ ($\mathbf{X} \sim \text{Dir}(\boldsymbol{\alpha})$) se, e somente se, sua p.d.f é dada por

$$f(\mathbf{x}; \boldsymbol{\alpha}) = \frac{\Gamma(\sum_{i=1}^n \alpha_i)}{\prod_{i=1}^n \Gamma(\alpha_i)} \prod_{i=1}^n x_i^{\alpha_i - 1},$$

onde $\alpha_i > 0$, $\forall i = 1, \dots, n$ e a densidade é zero se $x_i \notin [0, 1]$ para algum $i = 1, \dots, n$ ou $\sum_{i=1}^n x_i \neq 1$.

Multinomial (Generalização da Binomial)

Seja $\mathbf{X} \in \mathbb{R}^k$. Então, \mathbf{X} segue a distribuição multinomial com número de tentativas n e probabilidades p_1, \dots, p_k ($\mathbf{X} \sim \text{Mult}(n, [p_1, \dots, p_k])$) se \mathbf{X} é o número de observações pertencentes a k categorias distintas em n ensaios independentes, cuja densidade é dada por

$$f(\mathbf{x}; n, p_1, \dots, p_k) = \frac{n!}{\prod_{i=1}^k x_i!} \prod_{i=1}^k p_i^{x_i},$$

onde $\sum_{i=1}^k x_i = n$; $x_i \geq 0, \forall i = 1, \dots, k$; e $\sum_{i=1}^k p_i = 1$.

Pareto

Seja $\mathbf{X} \in \mathbb{R}^k$. Então, \mathbf{X} segue a distribuição de Pareto com parâmetros $a = (a_1, \dots, a_k)$ e p se sua p.d.f é dada por

$$f(\mathbf{x}; a, p) = \frac{p(p+1) \dots (p+k-1)}{\left(\prod_{i=1}^k a_i\right) \left[\left(\sum_{i=1}^k a_i^{-1} x_i\right) - k + 1\right]^{p+k}},$$

para $x_i > a_i > 0, i = 1, \dots, k, p > 0$.

Normal Matricial

Seja $\mathbf{X} \in \mathbb{R}^{n \times p}$. Então, \mathbf{X} segue a distribuição normal com média M , covariância entre linhas U e covariância entre colunas V ($\mathbf{X} \sim \mathcal{MN}(M, U, V)$) se, e somente se, sua p.d.f é dada por

$$f(\mathbf{X}; M, U, V) = \frac{1}{\sqrt{(2\pi)^{np} |V| |U|}} \exp \left[-\frac{1}{2} \text{tr}(V^{-1}(\mathbf{X} - M)^\top U^{-1}(\mathbf{X} - M)) \right].$$

Wishart (Generalização da Gamma)

Seja $\mathbf{X} \in \mathbb{R}^{n \times p}$, com $\mathbf{X} \sim \mathcal{MN}(0, I_n, V)$. Tome $S = \mathbf{X}^\top \mathbf{X}$. Então, S segue a distribuição de Wishart com matriz de escala V e n graus de liberdade ($S \sim \mathcal{W}(V, n)$), com $n > p - 1$ e V simétrica positiva definida. Sua p.d.f é dada por

$$f(\mathbf{X}; V, n) = \frac{1}{2^{np/2} |V|^{n/2} \Gamma_p(\frac{n}{2})} |\mathbf{X}|^{(n-p-1)/2} \exp \left(-\frac{1}{2} \text{tr}(V^{-1} \mathbf{X}) \right),$$

onde $\Gamma_p(\frac{n}{2}) = \pi^{p(p-1)/4} \prod_{j=1}^p \Gamma(\frac{n}{2} - \frac{j-1}{2})$.

Recursos para manipulação algébrica

Completar Quadrado Multidimensional

Tome \mathbf{X} matriz simétrica positiva definida $d \times d$ e $\mathbf{u}, \mathbf{v} \in \mathbb{R}^d$. Vale que

$$\mathbf{u}^\top X \mathbf{u} - 2\mathbf{v}^\top \mathbf{u} = \left(\mathbf{u} - X^{-1}\mathbf{v} \right)^\top X \left(\mathbf{u} - X^{-1}\mathbf{v} \right) - \mathbf{v}^\top X^{-1}\mathbf{v}.$$

Para verificar isso, basta expandir a forma quadrática e usar a simetria da matriz X :

$$\begin{aligned} \left(\mathbf{u} - X^{-1}\mathbf{v} \right)^\top X \left(\mathbf{u} - X^{-1}\mathbf{v} \right) &= \left(\mathbf{u}^\top X - \mathbf{v}^\top \left(X^\top \right)^{-1} X \right) \left(\mathbf{u} - X^{-1}\mathbf{v} \right), \\ &= \left(\mathbf{u}^\top X - \mathbf{v}^\top \right) \left(\mathbf{u} - X^{-1}\mathbf{v} \right), \\ &= \mathbf{u}^\top X \mathbf{u} - \mathbf{u}^\top \mathbf{v} - \mathbf{v}^\top \mathbf{u} + \mathbf{v}^\top X^{-1}\mathbf{v}, \\ &= \mathbf{u}^\top X \mathbf{u} - 2\mathbf{u}^\top \mathbf{v} + \mathbf{v}^\top X^{-1}\mathbf{v}. \end{aligned}$$

Distribuição Normal Multivariada

Distribuição Marginal

Seja $X \sim \mathcal{N}(\boldsymbol{\mu}, \boldsymbol{\Sigma})$, com $\boldsymbol{\mu} \in \mathbb{R}^d$ e $\boldsymbol{\Sigma} \in \mathbb{R}^{d \times d}$. Suponha que X pode ser particionado de forma que tenha-se

$$X = \begin{bmatrix} X_1 \\ X_2 \end{bmatrix}, \quad \boldsymbol{\mu} = \begin{bmatrix} \boldsymbol{\mu}_1 \\ \boldsymbol{\mu}_2 \end{bmatrix}, \quad \boldsymbol{\Sigma} = \begin{bmatrix} \boldsymbol{\Sigma}_1 & \boldsymbol{\Sigma}_2 \\ \boldsymbol{\Sigma}_2^\top & \boldsymbol{\Sigma}_3 \end{bmatrix}$$

com $\boldsymbol{\mu}_1 \in \mathbb{R}^k$, $\boldsymbol{\mu}_2 \in \mathbb{R}^{d-k}$, $\boldsymbol{\Sigma}_1 \in \mathbb{R}^{k \times k}$, $\boldsymbol{\Sigma}_2 \in \mathbb{R}^{k \times (d-k)}$ e $\boldsymbol{\Sigma}_3 \in \mathbb{R}^{(d-k) \times (d-k)}$, para $k < d$. Então, $X_1 \sim \mathcal{N}(\boldsymbol{\mu}_1, \boldsymbol{\Sigma}_1)$ e $X_2 \sim \mathcal{N}(\boldsymbol{\mu}_2, \boldsymbol{\Sigma}_3)$.

Distribuição Condicional

Considere X como anteriormente. Então,

$$\begin{aligned} X_1 \mid X_2 &\sim \mathcal{N}(\hat{\boldsymbol{\mu}}_1, \hat{\boldsymbol{\Sigma}}_1) \text{ com } \begin{cases} \hat{\boldsymbol{\mu}}_1 = \boldsymbol{\mu}_1 + \boldsymbol{\Sigma}_2 \boldsymbol{\Sigma}_3^{-1} (X_2 - \boldsymbol{\mu}_2) \\ \hat{\boldsymbol{\Sigma}}_1 = \boldsymbol{\Sigma}_1 - \boldsymbol{\Sigma}_2 \boldsymbol{\Sigma}_3^{-1} \boldsymbol{\Sigma}_2^\top \end{cases}, \\ X_2 \mid X_1 &\sim \mathcal{N}(\hat{\boldsymbol{\mu}}_2, \hat{\boldsymbol{\Sigma}}_2) \text{ com } \begin{cases} \hat{\boldsymbol{\mu}}_2 = \boldsymbol{\mu}_2 + \boldsymbol{\Sigma}_2 \boldsymbol{\Sigma}_1^{-1} (X_1 - \boldsymbol{\mu}_1) \\ \hat{\boldsymbol{\Sigma}}_2 = \boldsymbol{\Sigma}_2 - \boldsymbol{\Sigma}_2 \boldsymbol{\Sigma}_1^{-1} \boldsymbol{\Sigma}_2^\top \end{cases}. \end{aligned}$$

Combinação Linear

Tome $X \sim \mathcal{N}(\boldsymbol{\mu}_X, \boldsymbol{\Sigma}_X)$ e $Y \sim \mathcal{N}(\boldsymbol{\mu}_Y, \boldsymbol{\Sigma}_Y)$. Então,

$$AX + BY + \mathbf{c} \sim \mathcal{N} \left(A\boldsymbol{\mu}_X + B\boldsymbol{\mu}_Y + \mathbf{c}, A\boldsymbol{\Sigma}_X A^\top + B\boldsymbol{\Sigma}_Y B^\top \right).$$

Referências

- Petersen, K. B. e M. S. Pedersen (out. de 2008). *The Matrix Cookbook*. Version 20081110. URL: <http://www2.imm.dtu.dk/pubdb/p.php?3274>.
- Soch, Joram et al. (jan. de 2024). *StatProofBook/StatProofBook.github.io: StatProofBook 2023*. Versão 2023. DOI: [10.5281/zenodo.10495684](https://doi.org/10.5281/zenodo.10495684). URL: <https://doi.org/10.5281/zenodo.10495684>.